Emoji Platform Recognition

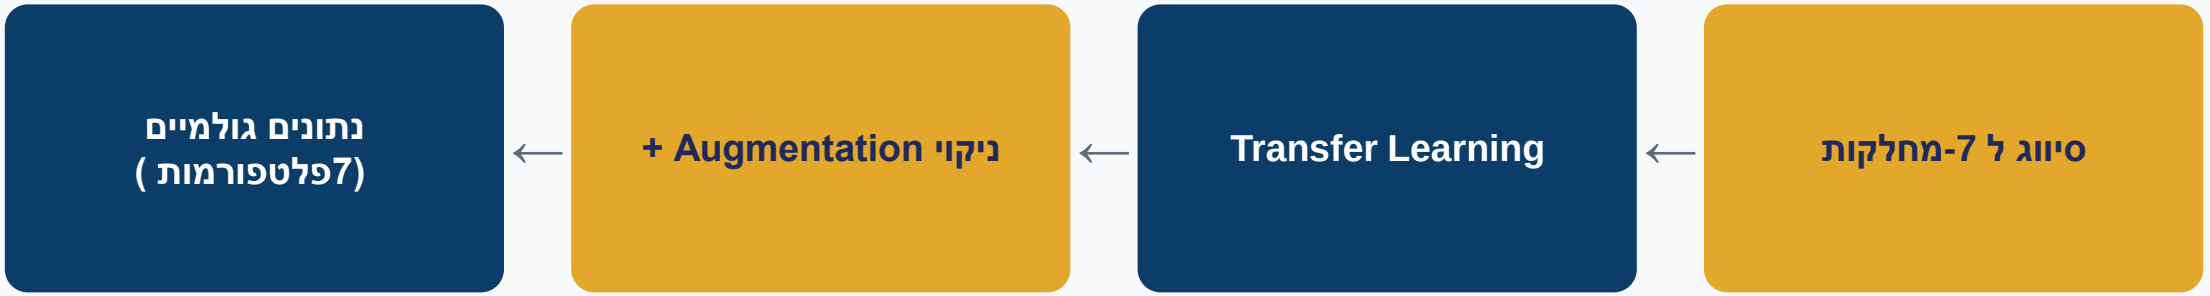
סיווג פלטפורמת מקור לאימוג׳י באמצעות Transfer Learning



חגית מילצקי | פרויקט סיום — Deep Learning

🎯 מטרת הפרויקט

בניית מערכת המסווגת לאיזו פלטפורמה שייך אימוג׳י נתון, תוך שימוש בשיטות Deep Learning מתקדמות ומחזור עבודה מלא — מנתונים גולמיים ורועשים ועד מודל מאומן ומוערך.



💼 ערך מוצרי/עסקי

בקרת עקביות עיצובית ואיכות (QA)לפני פרסום נכסי אימוג׳י •זיהוי אוטומטי של מקור תמונה לצורכי Asset Managementבקנה מידה •אימות התאמת סגנון בעת ייצור אימוג׳ים חדשים ע"י כלים גנרטיביים (ראו שקף בונוס —שילוב כ Tool-בסוכן .AI)

🗂️ מאגר הנתונים Emoji Dataset —

כל אימוג׳י קיים ב 7-פלטפורמות שונות .התמונות התקבלו כ Base64-ופוענחו לקבצי ,PNGמאורגנים בתיקיות לפי פלטפורמה.

12,001

אחרי ניקוי

7

פלטפורמות

12,169

תמונות גולמיות


Apple


Google


Facebook


Windows


Twitter


JoyPixels



Samsung

🗑️ דוגמאות לנתונים "מלוכלכים"בדאטהסט

לפני הניקוי, הדאטהסט הגולמי הכיל בעיות אופייניות: תמונות עם מימדים חריגים, וחשד לתיוגים שגויים בין פלטפורמות.



כל הדוגמאות שנבדקו נבחרו אוטומטית על בסיס בדיקות שנבנו לצורך המטלה (Outlier Detection)ו Average Hash-לזיהוי חשד ל — (Mislabel-לא נבחרו ידנית.

🧹 ניקוי נתונים —הסרת כפילויות

זוהו תמונות זהות (Duplicate)בין הפלטפורמות באמצעות Hashingעל תוכן הקובץ ,והוסרו —למניעת Data Leakageבין קבוצות ה-Train/Val/Test.

12,169 → 12,001

לפני → אחרי

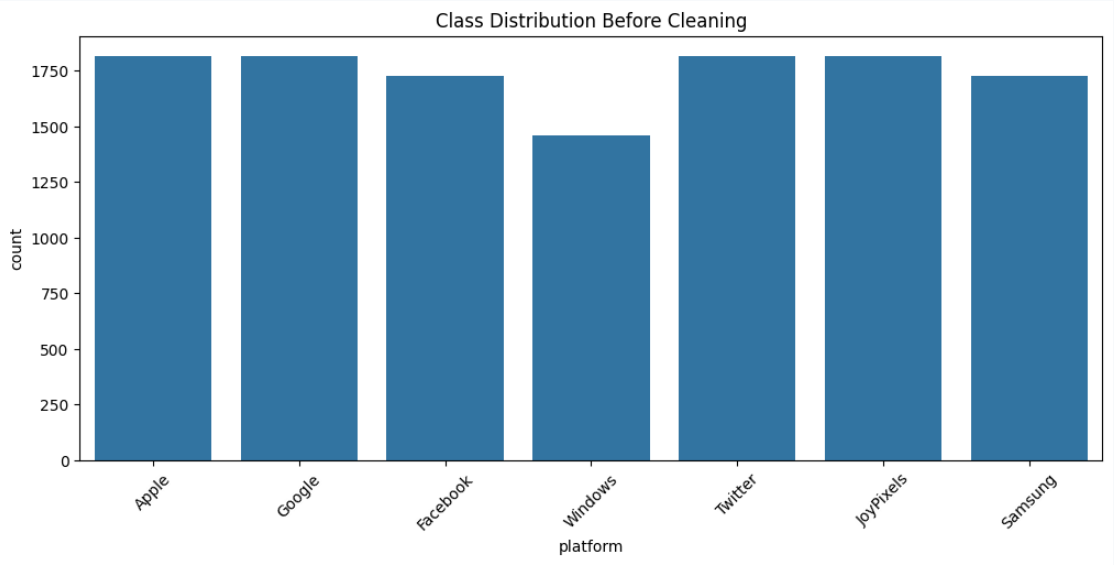
168

תמונות הוסרו

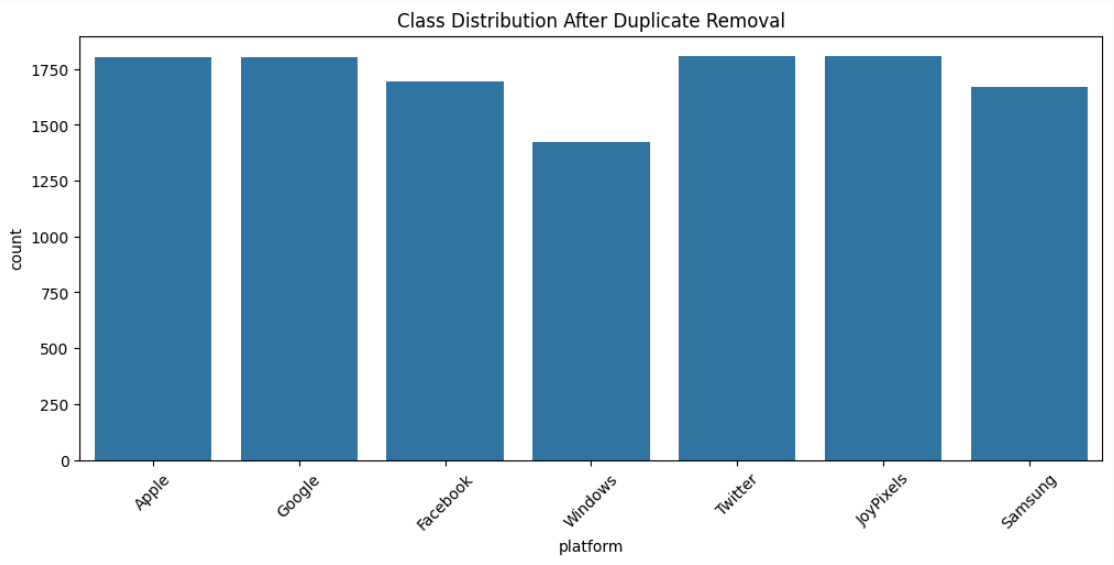
125

קבוצות כפילויות שזוהו

📊 התפלגות מחלקות —לפני ואחרי ניקוי



לפני ניקוי



אחרי ניקוי

ההתפלגות נותרה מאוזנת יחסית בין הפלטפורמות גם לאחר הסרת הכפילויות.

🔍 בדיקת חריגים ותיוגים שגויים

Mislabeled Data

2,933

מועמדים סומנו לבדיקה)שיטת Average Hashמול תבנית הקבוצה .(
המספר הגבוה משקף בעיקר הבדלי סגנון לגיטימיים בין פלטפורמות —
לא בהכרח תיוג שגוי —ודורש כיול סף וסינון ידני נוסף.

Outliers

2

תמונות עם מימדים חריגים אותרו 108×108)פיקסלים לעומת 72×72
הסטנדרטי — (נבדקו ידנית ואושרו כתקינות.

Data Augmentation 🔄

מיושם רק על קבוצת ה Train-, למניעת Overfitting. Validation/Test עוברים Resize בלבד.

RandomHorizontalFlip

היפוך אופקי אקראי

RandomRotation

סיבוב אקראי מתון (±10°)

ColorJitter

שינוי עדין בבהירות/ניגודיות

⚠️ **שיקול מתודולוגי: מדוע לא הוחל Augmentation אגרסיבי יותר**

בשונה ממשימות סיווג תמונות רגילות, כאן משימת הסיווג מבוססת בדיוק על ההבדלים העדינים בסגנון הוויזואלי בין הפלטפורמות —גוון הצבע, קווי המתאר ופרטי העיצוב. מסיבה זו, הוחלט במכוון להימנע מ Augmentation-אגרסיבי (כגון שינויי צבע קיצוניים, עיוותים גיאומטריים משמעותיים, או שינויי קנה-מידה חדים) שינוי כזה עלול לטשטש בדיוק את המאפיינים המבחינים בין הפלטפורמות, ואף לגרום לתמונה מפלטפורמה אחת להידמות ויזואלית לפלטפורמה אחרת —מה שהיה עלול להזין את המודל בסימון שגוי ולפגוע באמינות התיוג ובדיוק הסיווג.

🧠 ארכיטקטורות וTransfer Learning-

שיטה Freeze: של ה ,Backbone-החלפת שכבת ה Classifier-ל 7-מחלקות —אימון רק שכבת ה.Classifier-

🔧 טכניקת Fine-Tuningשנבחרה(Feature Extraction (Frozen Backbone :

נבחרה במקום Fine-Tuningמלא)שחרור שכבות פנימיות (מטעמי יעילות חישובית ומניעת Overfittingעל דאטהסט קטן-בינוני ~12K)תמונות .(נימוק בחירת הרשתות ResNet50 :
כרשת מבוססת ומוכחת ,ו EfficientNet-B0-לבחינת יעילות פרמטרית ~5x)פחות פרמטרים (מול דיוק.

ResNet50

Notebook 05

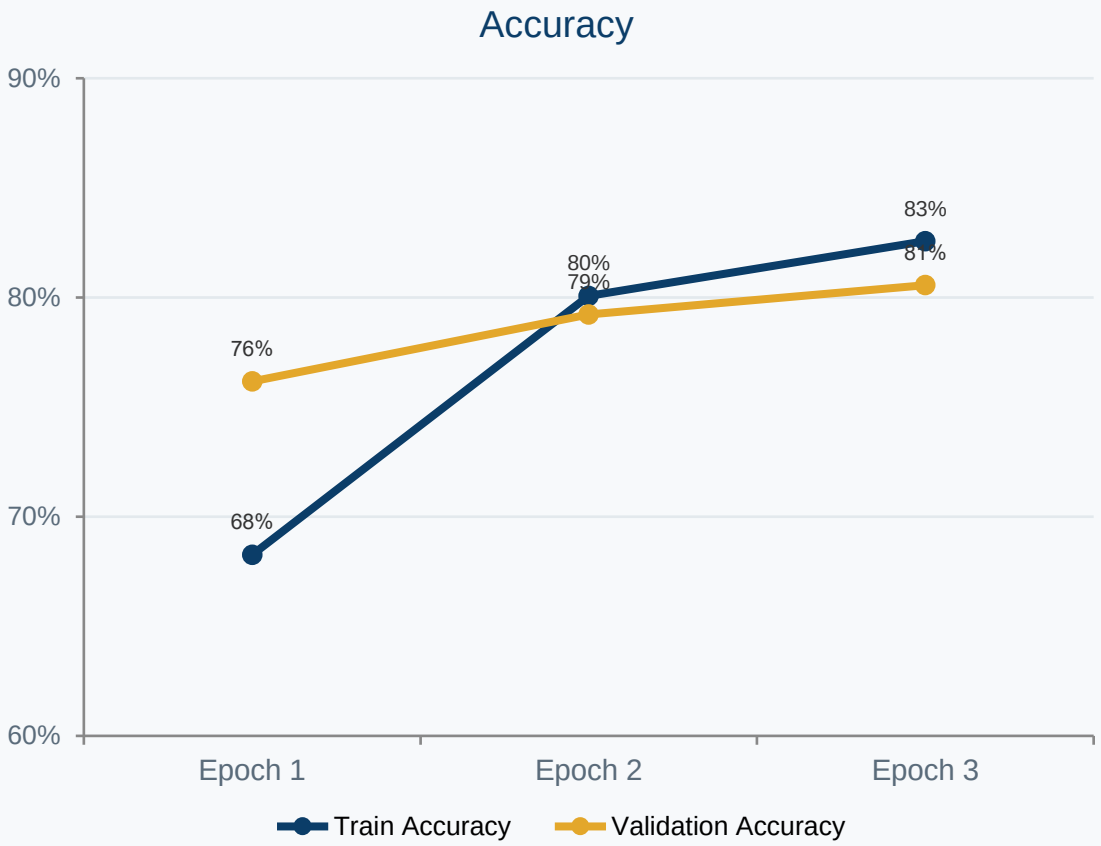
פרמטרים: ~25.6M
Weights: ImageNet Pretrained

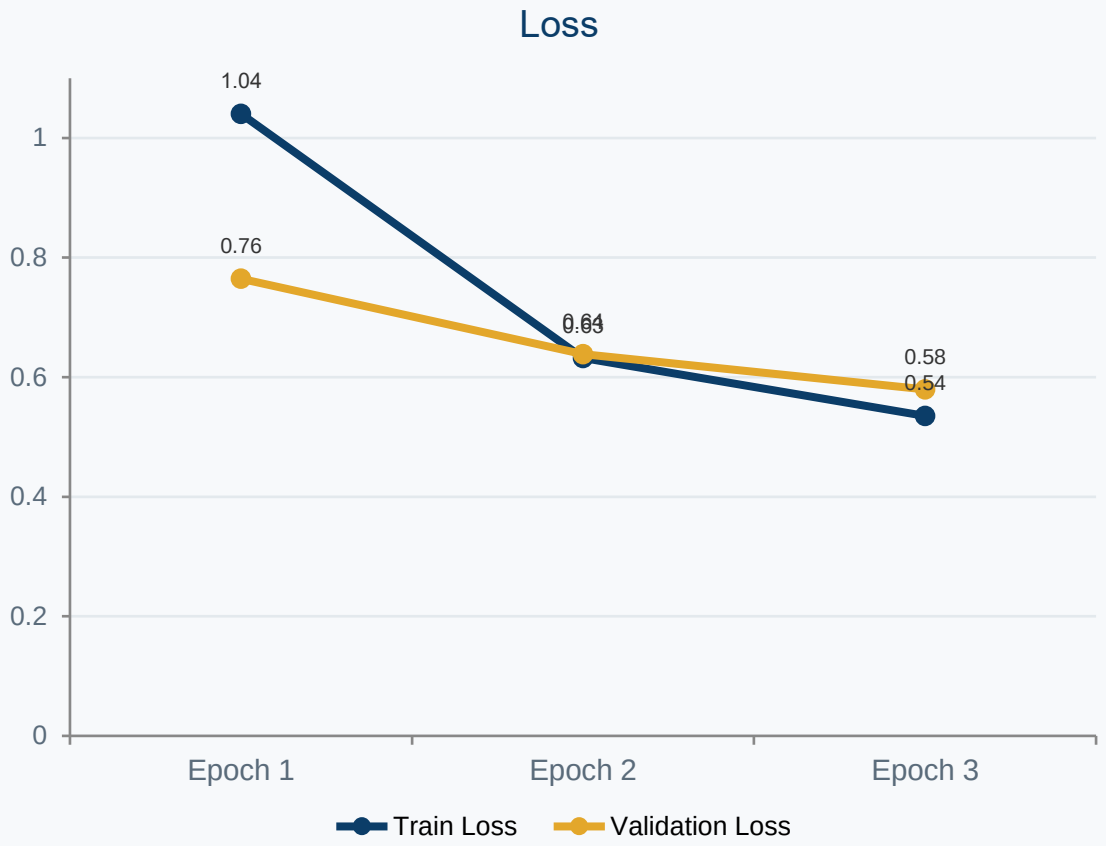
EfficientNet-B0

Notebook 06

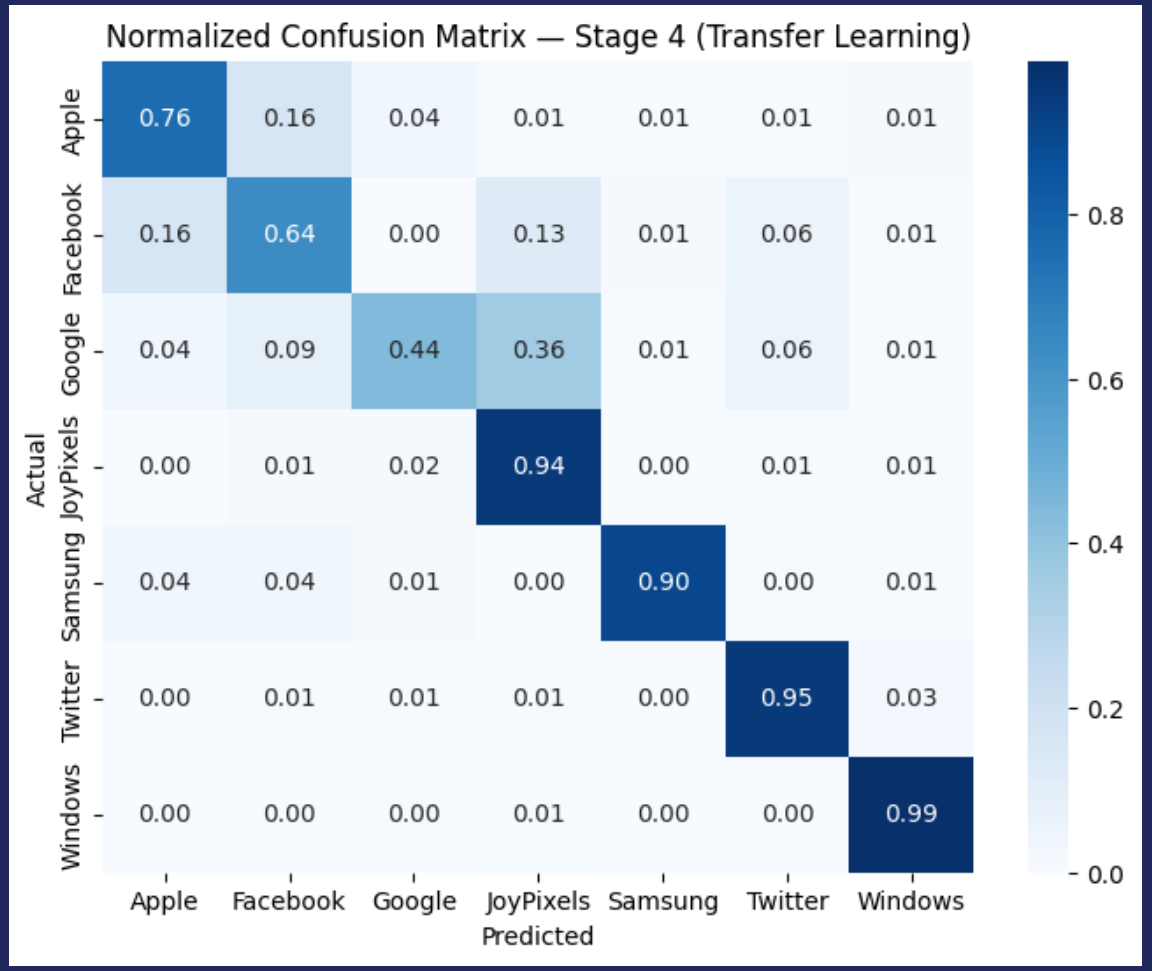
פרמטרים: ~5.3M
Weights: ImageNet Pretrained

Learning Curves—המודל הסופי (שלב 4) 📈





Confusion Matrix—מנורמל (שלב 4) 🧩

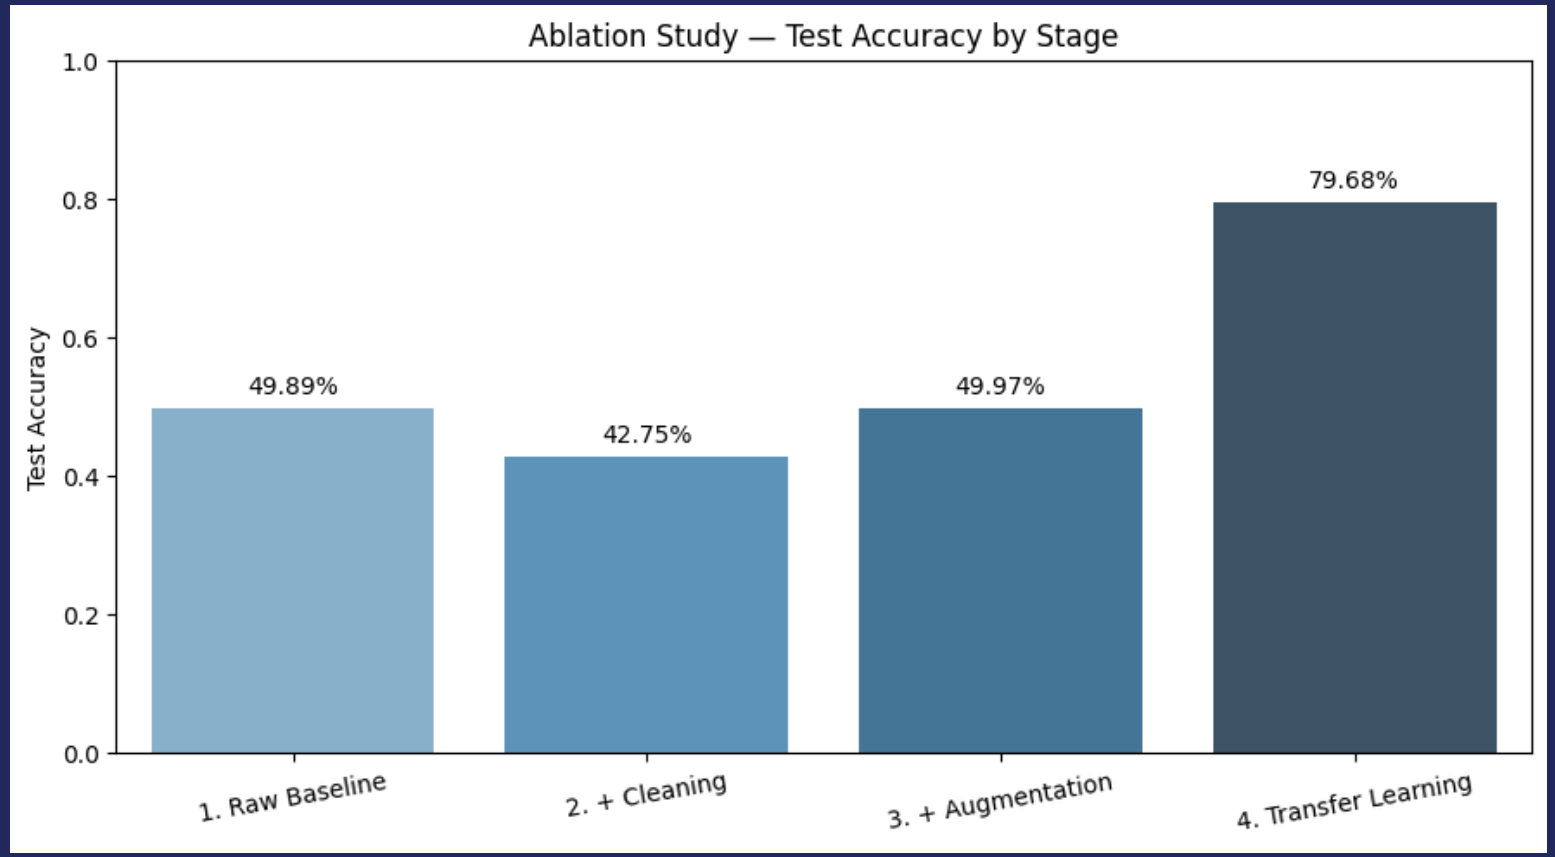


🧪 Ablation Study—מבנה הניסוי

כל שלב משנה משתנה אחד בלבד, כדי לבודד את התרומה הנקייה שלו.

#	שלב	נתונים מנוקים	Augmentation	Pretrained
1	Baseline גולמי	✗	✗	✗
2	+ Cleaning	✓	✗	✗
3	+ Augmentation	✓	✓	✗
4	Transfer Learning	✓	✓	✓

📉 Ablation Study—תוצאות (Test Accuracy)



שלבים 1–3 (Backbone קפוא ואקראי (מציגים ביצועים דומים ורועשים — (~43–50%)ההבדלים ביניהם בעיקר רעש סטטיסטי .הקפיצה המשמעותית בשלב 4. Pretrained Weights והברורה מגיעה עם

🕵️ Error Analysis—ניתוח טעויות המודל

מתוך 1,801תמונות בסט הטסט, המודל טעה ב) 367-כ .(20.4%-שלוש דוגמאות מייצגות לטעויות אופייניות:



הסבר :מדוע המודל טועה בעיקר בין הזוגות האלה?

לפי ה ,Confusion Matrix-ריכוז הטעויות הגבוה ביותר הוא בין Googleל (36%) JoyPixels-ובין Facebookל — (13%) JoyPixels-פלטפורמות שמשתמשות בסגנון עיצוב שטוח (Flat Design)וגוני צבע דומים יחסית לאותו אימוג׳י, מה שמקשה על המודל להבחין ביניהן במיוחד כשה Backbone-קפוא וממוקד רק בשכבת הסיווג). יש לוודא שההסבר תואם את שלוש הדוגמאות שהתקבלו בפועל, ולעדכן במידת הצורך.

🏆 התוצאה הסופית

49.9%

Baseline(שלב1)

→

79.7%

Transfer Learning(שלב 4)

שיפור יחסי של 59.7% (נקודות אחוז 29.8+)

מעבר לקריטריון ה 15%-המקורי —ומעל ומעבר לדרישת "שיפור כלשהו"

💡 מסקנות ותובנות

1

Pretrained Weightsהם הגורם המכריע

התרומה של Transfer Learning (+~30נק׳ אחוז (גבוהה בהרבה מהתרומה הנפרדת של ניקוי או Augmentationלבד.

2

תוצאות שלבים 3–1רועשות מטבען

Backboneאקראי וקפוא מגביל את יכולת הלמידה ,כך שהפרשים קטנים ביניהם משקפים בעיקר רעש ולא אפקט אמיתי וחד-משמעי.

3

Mislabeled Detectionדורש כיול נוסף

השיטה שנבנתה מזהה גם הבדלי סגנון לגיטימיים בין פלטפורמות —נדרש סף גבוה יותר ובדיקה ידנית לפני מחיקת נתונים.

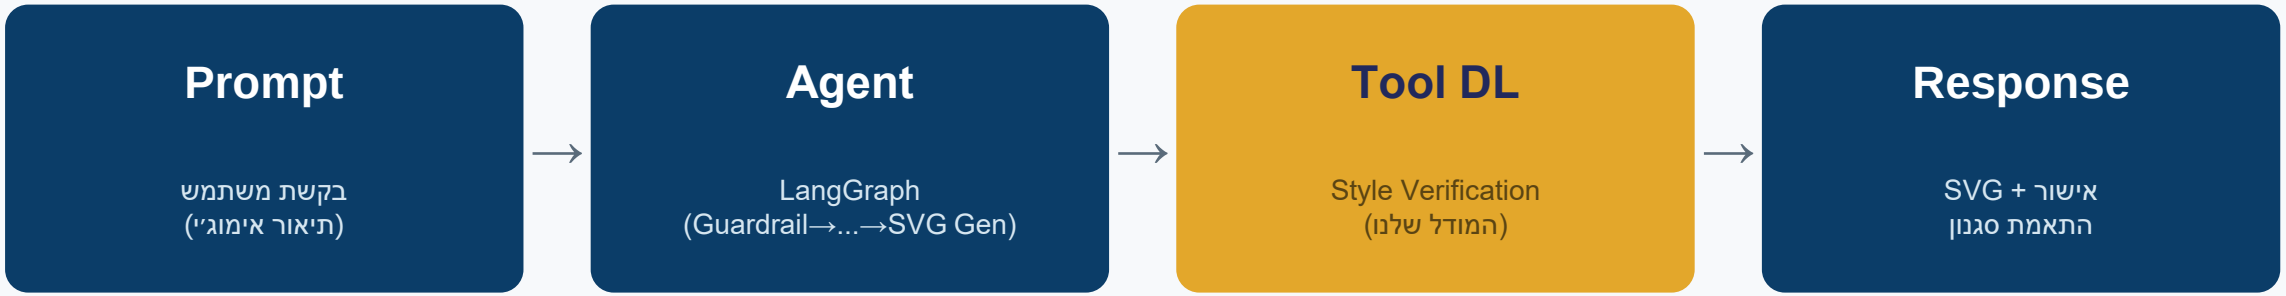
4

כיוונים להמשך

Fine-Tuningשל שכבות נוספות)לא רק ה ,(Classifier-הרצה עם יותר Epochs, ובדיקת ארכיטקטורות נוספות.

🤖 בונוס: שילוב המודל כ Tool-בסוכן AI

המודל המאומן נעטף כ) Tool-פונקציית (Pythonבתוך סוכן LangGraphשמעצב אימוג'ים חדשים —ומשמש כשכבת QAאוטומטית שבודקת האם הסגנון שנוצר בפועל תואם ויזואלית לפלטפורמת היעד שהתבקשה.



דוגמה מאוירת להרצה — (Illustrativeממחישה את זרימת המידע בפועל)

Prompt: "פרצוף שמח עם עיניים נוצצות, בסגנון Apple" → Agent: מזהה רגש+מחווה, בונה מפרט עיצובי, מייצר SVG → Tool DL: מסווג את ה SVG-שנוצר predicted_platform="Apple", confidence=0.91, matches_target=True → Response: SVG ומחזיר מאושר +אינדיקציה שהסגנון תואם.

🙏 תודה!

שאלות?

github.com/chagitmi/emoji-platform-recognition-transfer-learning